SEPA: resultados de la exploración (etapas 0 y 1)

Oct 17, 2026 · @Nicolas

Resumen

La etapa 1 está completa: el archivo se puede procesar, un día pesa 70 MB en Parquet y solo el 2,6 % de las filas cambia o reaparece de un día para otro. Lo único que bloquea el pipeline es el acceso: el portal rechaza las descargas desde la nube.

- **Acceso:** el portal responde 403 a GitHub Actions y a Google Colab, y 200 desde la PC de casa. La etapa 0 no está cumplida.
- **Volumen:** un día trae unos 14 millones de filas en los 7 comercios conservados. En Parquet pesa 70 MB, 21 veces menos que el CSV, y un año ocupa unos 25 GB de los 400 GB de Drive.
- **Productos:** el 66,9 % de los precios corresponde a códigos que aparecen en 2 o más comercios.
- **Cambios:** guardando solo lo que cambia se escriben unas 148 millones de filas por año, en lugar de 5.100 millones con una foto por día.
- **Decisiones tomadas:** 5 preguntas, los 7 comercios, el precio de lista y el detalle completo en Drive.

Todo se midió sobre archivos reales de 7 fechas, del 9 al 17 de octubre de 2026, con pandas y DuckDB en la PC. Cada cifra sale de una consulta y se controló contra los totales.

Preguntas del proyecto y decisiones tomadas

El proyecto va a responder 5 preguntas: las 3 del plan original, una sobre promociones y otra sobre cómo evoluciona cada producto.

#	Pregunta	Dónde se responde	Desde cuándo
1	¿Cuánto sube una canasta fija de productos, mes a mes y por cadena?	`fct_canasta`	Con al menos 2 meses de datos acumulados

#	Pregunta	Dónde se responde	Desde cuándo
2	¿En qué provincias son más caros los mismos productos?	`fct_precios_agregados`	Desde el primer día
3	¿Cuánto varía el precio de un mismo producto entre cadenas y entre sucursales?	`fct_precios_agregados`	Desde el primer día
4	¿Cuánto descuento real dan las promociones?	`fct_precios_agregados`	Desde el primer día, solo para las cadenas que informan promociones
5	¿Cómo evolucionó el precio de cada producto?	`fct_canasta` en el sitio y `fct_precios_producto` en BigQuery	Desde el primer día

Decisiones tomadas:

- **Precio:** el de lista para las preguntas 1, 2, 3 y 5. El Anexo II lo define sin descuentos y con cualquier medio de pago. Las promociones se usan solo para la pregunta 4, en columnas aparte.
- **Archivo en Drive:** el detalle completo de las 7 cadenas en todo el país, en tres archivos por día: precios (sucursal × producto), productos (comercio × código) y sucursales. La medición lo confirmó: unos 25 GB por año.
- **BigQuery (propuesta):** `dim_productos`, `dim_comercios`, `dim_sucursales`, `fct_canasta` y `fct_precios_agregados`. Para la pregunta 5 se agrega `fct_precios_producto` (producto × comercio × día).

Nuevas decisiones pendientes:

- ¿Se guarda una foto por día o un historial de cambios con fechas desde y hasta? ¿Cuántos días puede faltar un producto sin que se cierre su precio?
- ¿Con qué grano va `fct_precios_agregados`: con o sin provincia, diario o semanal?
- Etapa 5: ¿dónde se aloja el sitio y cómo consulta los datos, con JSON estáticos o con una API (Cloud Run u otro proveedor) sobre BigQuery?
- Canasta: el archivo no trae categoría de producto, así que una canasta equilibrada por rubros requiere clasificar los productos a mano o por su descripción.

Acceso al portal (etapa 0)

Desde la nube el portal rechaza todas las conexiones. Tanto la API como la descarga devuelven HTTP 403 con una página HTML en lugar del archivo.

Origen	API del catálogo	Descarga del zip
GitHub Actions	403	403
Google Colab	403	403
PC de casa (curl)	200	200

- La página del 403 trae protecciones de script (CSP con nonces), algo típico de un filtro anti-bots. El bloqueo depende de la dirección IP. Todavía no se sabe si filtra por centro de datos o por país.
- El bloqueo no se va a evadir: nada de proxies, ni de cambiar la identidad del navegador, ni de navegadores automatizados.
- El dataset tiene 9 recursos: 7 zips, uno por día de la semana (de 310 a 328 MB cada uno), un Excel con los códigos de provincia y un PDF de metadatos (Anexo II).
- La licencia es CC BY 4.0, confirmada en la página del dataset. Lo mantiene la Dirección de Evaluación y Monitoreo de Precios (soportesepa@comercio.gob.ar).

Horario de publicación observado en la semana del 12/10/2026:

Archivo	Cuándo apareció
Sábado 17	Ya estaba a las 15:00 (Argentina), y las 16 carpetas tienen fecha 2026-10-17
Viernes 16	Todavía no publicado el sábado 17 a las 13:05
Martes, miércoles y jueves	El mismo día, a las 13:19 de Argentina (16:19 UTC)
Sábado 10, domingo 11 y lunes 12	Subidos juntos el martes 13

El Anexo II fija que los comercios envían los datos hasta las 06:00 del día en que rigen los precios, y pueden rectificarlos hasta las 10:00. La publicación en el portal, a las 13:19, es posterior a ese límite.

Estructura y formato del archivo

El zip del día contiene una carpeta con la fecha (`AAAA-MM-DD/`). Dentro hay un zip por comercio, y cada uno trae tres CSV: `comercio.csv` , `sucursales.csv` y `productos.csv` .

- El zip interno se llama `sepa_<1|2>_comercio-sepa-<N>_<fecha>_<HH-MM-SS>.zip`, así que el comercio y la fecha se leen del nombre.
- Separador `|` y codificación UTF-8 con BOM: se lee con `encoding="utf-8-sig"`. El fin de línea es LF o CRLF según el comercio.
- Todo se lee como texto. Si no, los ids, el CUIT y los códigos de producto pierden los ceros a la izquierda.
- Cada archivo termina con un pie, "Última actualización: <fecha y hora>", cuyo texto varía ("Ultima" o "Última"). La regla es descartar las filas cuyo `id_comercio` no sea numérico y contarlas.
- La provincia de la sucursal viene como código ISO, por ejemplo `AR-Y`.

`productos.csv` tiene 17 columnas:

Grupo	Columnas
Dónde	`id_comercio`, `id_bandera`, `id_sucursal`
Producto	`id_producto`, `productos_ean`, `productos_descripcion`, `productos_marca`
Presentación	`productos_cantidad_presentacion`, `productos_unidad_medida_presentacion`
Precio	`productos_precio_lista`
Precio por unidad de referencia	`productos_precio_referencia`, `productos_cantidad_referencia`, `productos_unidad_medida_referencia`
Promociones	`productos_precio_unitario_promo1`, `productos_leyenda_promo1`, `productos_precio_unitario_promo2`, `productos_leyenda_promo2`

- Los precios vienen con punto decimal y dos decimales (`5830.00`). Las promociones quedan vacías cuando no hay.
- `precio_referencia` es el precio por kg, litro o unidad. Por ejemplo, 5830 por 100 g da 58.300 por kg. Se verificó en 3 filas.

El Anexo II (la especificación oficial, de diciembre de 2020) confirma el formato y muestra qué anomalías son incumplimientos de los comercios:

- **Fin de línea y pie:** la norma pide `\r\n`, una línea en blanco y después el pie `Última actualización: AAAA-MM-DDTHH:MM:SS-03:00`. Los archivos con LF o con "Ultima" sin tilde no la cumplen.

- **Saltos de línea dentro de un valor:** la norma los prohíbe. Lo del comercio 6 es un error de ese comercio.
- **Versión del modelo:** `comercio.csv` trae `comercio_version_sepa`. Podría explicar el prefijo `sepa_1` / `sepa_2` del zip (el sábado, 11 comercios son sepa_1 y 5 son sepa_2, sin relación con el tamaño), pero no está comprobado.
- **Tipo de sucursal:** `sucursales_tipo` vale Hipermercado, Supermercado, Autoservicio, Tradicional o Web. Las sucursales web no tienen latitud ni longitud.
- **Productos a granel:** llevan cantidad de presentación 1.
- **Precios:** el de lista no tiene descuentos y vale con cualquier medio de pago y sin tarjeta de fidelidad. La promo 1 es de alcance general. La promo 2 es especial: con tarjeta, con un medio de pago o para jubilados, por ejemplo.

Volumen

Un día trae entre 14,1 y 14,2 millones de filas de productos, por encima de los 12 millones que estimaba el plan. En un año son más de 5.000 millones de filas.

Medida	Jueves 15/10	Sábado 17/10
Filas de productos, todos los comercios	14.121.656	≈ 14,20 millones
Filas de los 7 comercios conservados	13.982.859	14.041.412
Sucursales	2.675 (15 comercios)	2.511 (los 7 comercios)
Comercios con datos	15 (y el 36 vacío)	16 (aparece el 8 y falta el 36)

- El tamaño comprimido no predice las filas: va de 27.000 a 182.000 filas por MB comprimido, según el comercio.
- Descomprimido ocupa unas 3,1 veces lo comprimido. Se midió en el comercio 10, cuyo `productos.csv` pesa 392 MB.
- Cada comercio cambió entre −0,4 % y +1,1 % de jueves a sábado. Cencosud casi no cambió: solo 200 filas.
- El volumen viene de las sucursales, no del catálogo. Hay unos 113.500 pares comercio × código por día, con unas 124 filas cada uno. DIA, por ejemplo, tiene 4.444 códigos y 4,18 millones de filas.

El peso en Parquet y las filas que quedan después de agregar están en la sección siguiente.

Mediciones en Parquet y agregados

Un día de los 7 comercios pesa 70,2 MB en Parquet, 21 veces menos que los 1.506 MB del CSV, así que un año de detalle completo ocupa unos 25 GB de los 400 GB de Drive.

Comercio	Filas, sábado 17/10	CSV (MB)	Parquet (MB)	Veces más chico	Filas con promoción
DIA (15)	4.176.726	494,3	8,9	55,5	31,9 %
INC (10)	3.487.088	377,0	37,0	10,2	4,9 %
Dorinka (11)	2.327.821	199,6	7,3	27,3	0,0 %
Cencosud (9)	1.268.365	141,0	4,1	34,4	0,0 %
COTO (12)	1.054.215	109,8	4,7	23,4	0,8 %
La Anónima (2)	1.014.507	114,6	4,5	25,5	5,5 %
Coop. Obrera (13)	712.690	69,3	3,7	18,7	9,9 %

- El jueves 15/10 dio casi lo mismo: 69,9 MB.
- INC ocupa más de la mitad del peso con el 25 % de las filas. Tiene 37.267 productos y sus valores se repiten menos que los de DIA, que tiene 4.444 productos en 972 sucursales.
- Cencosud y Dorinka no informaron ninguna promoción ni el jueves ni el sábado, y COTO casi ninguna. La pregunta 4 queda limitada a DIA, INC, La Anónima y Coop. Obrera.

Filas según el grano de agregación, medidas el sábado 17/10:

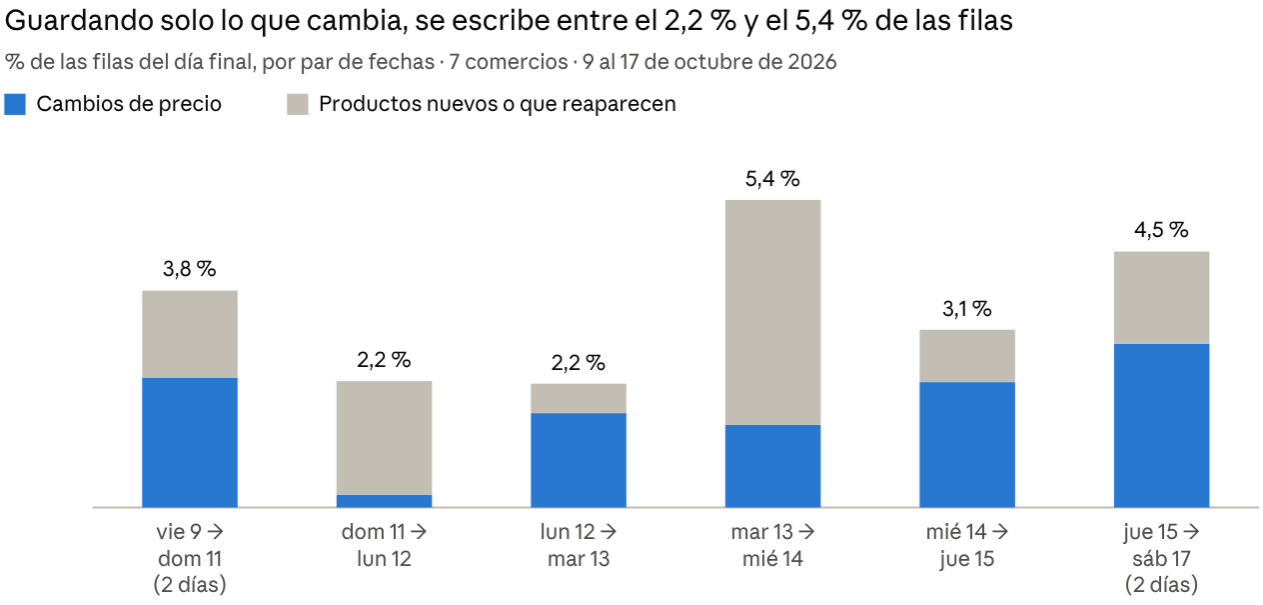
Grano	Filas	Filas por año	BigQuery por año (estimado)
Detalle sucursal × producto, diario	14.041.412 por día	5.125 millones	— (solo va a Drive)
Detalle como historial de cambios	367.727 escrituras por día	≈ 148 millones	≈ 12,7 GB
Producto × comercio × provincia, diario	1.406.169 por día	513 millones	≈ 65 GB
Producto × comercio × provincia, semanal	≈ 1,4 millones por semana	73 millones	≈ 9 GB
Producto × comercio × provincia, como historial de cambios	—	≈ 15 millones	≈ 1,9 GB

Grano	Filas	Filas por año	BigQuery por año (estimado)
Producto × comercio, diario	113.522 por día	41 millones	≈ 5 GB

Los GB son estimaciones con un tamaño de fila supuesto: 137 bytes los agregados y 92 el detalle. La fila del historial por provincia supone además que las medianas cambian al mismo ritmo que los precios individuales (2,63 % por día).

Una semana de datos: cuánto cambia cada día

Guardando solo lo que cambia, cada día se escriben en promedio 367.727 filas, el 2,6 % de un día. La mitad son cambios de precio (184.717 por día) y la otra mitad, productos nuevos o que vuelven a aparecer (183.010 por día).



Del 10 no hay archivo y el 16 todavía no estaba publicado: esos dos pares abarcan 2 días.

Parquet de las 7 fechas del 9 al 17/10/2026, comparadas con DuckDB · 7 comercios

- **Casi todos los cambios son permanentes.** Entre el viernes 9 y el sábado 17 cambió el 9,43 % de los precios, y el 9,7 % de las claves sucursal × producto cambió al menos una vez.
- **Del domingo al lunes casi no cambian precios (0,22 %).** La excepción es COTO, que cambia todos los días, entre 1 y 2,6 %.
- **Las cadenas remarcan en tandas.** INC va de 0,01 % a 5,31 % según el día, y Cencosud llega a 6,42 % de martes a miércoles. En la semana, la proporción de claves que cambió de precio va del 3,2 % (Dorinka) al 15,2 % (Cencosud).

- **El historial ocupa poco.** En una semana son 17,0 millones de filas contra 97,8 millones de la foto diaria. En un año serían unos 148 millones contra 5.100 millones (2,9 %).
- **Los picos de "nuevos" son productos que vuelven.** El 13/10 faltaron 421.004 filas de DIA y volvieron el 14 (ver Problemas de calidad).

Decisión resuelta: comercios que se conservan

Se conservan los 7 comercios más grandes. Suman el 99,02 % de las filas del jueves y el 98,87 % del sábado, y fueron los mismos 7, en el mismo orden, los dos días.

id	Razón social	Banderas	Filas, sábado 17/10	% del día
15	DIA Argentina S.A.	Supermercados DIA	4.176.726	29,41
10	INC S.A.	Carrefour (Express, Hipermercado, Market, Maxi)	3.487.088	24,55
11	DORINKA SRL	Changomas, HiperChangomas, SuperChangomas	2.327.821	16,39
9	Cencosud S.A.	Vea, Disco, Jumbo	1.268.365	8,93
12	COTO CICSA	COTO	1.054.215	7,42
2	S.A. Importadora y Exportadora de la Patagonia	La Anónima	1.014.507	7,14
13	Cooperativa Obrera Ltda. de Consumo y Vivienda	Cooperativa Obrera	712.690	5,02

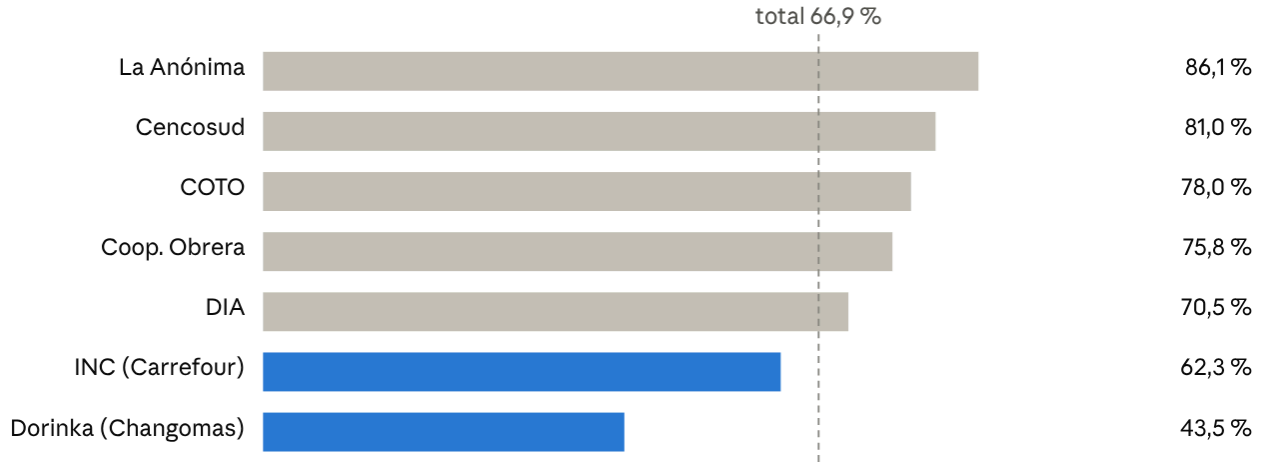
- Quedan afuera 8 comercios chicos, con el 0,98 % de las filas del jueves. El mayor de ellos, el 21, tiene el 0,42 %. Entre los descartados están el 6 y el 36, que tienen archivos dañados.
- La lista de los 7 va explícita en la configuración. Es una lista de comercios que sí se procesan, no "todos menos los que fallan".
- Si falta el archivo de uno de los 7, o viene dañado, el pipeline falla y avisa. Esos comercios pesan entre el 5 y el 29 % del día, así que saltearlos en silencio dejaría un hueco grande.
- Cada día se registra cuántas filas tienen los comercios descartados, para notar si alguno crece.

Identidad de productos y comparabilidad

Dos de cada tres precios (66,9 %, es decir 9.392.583 de las 14.041.412 filas del sábado) son de productos cuyo código aparece en 2 o más de los 7 comercios.

2 de cada 3 precios son comparables; Dorinka e INC quedan por debajo

% de filas con un código presente en 2 o más de los 7 comercios · sábado 17/10/2026



En azul, los comercios por debajo del total.

Notebook de pandas sobre los archivos del sábado 17/10/2026 · 7 comercios, 14.041.412 filas

Qué es `id_producto`:

- En la mayoría de las filas es el código de barras (EAN-13, EAN-8 o UPC-A), rellenado con ceros hasta 13 dígitos. Se tomaron 15 códigos compartidos al azar, y en todos los comercios la descripción correspondía al mismo producto.
- `productos_ean = 0` marca códigos internos. En INC, COTO y La Anónima son de balanza (13 dígitos que empiezan con 2); en Cencosud y Coop. Obrera, internos de 6 dígitos.
- `productos_ean = 1` no garantiza que sea un EAN. DIA nunca usa el 0 y marca como 1 sus frutas y verduras a granel: 33.033 filas con códigos `249…` y dígito verificador inválido.
- Que el dígito verificador sea válido tampoco prueba que sea un EAN: los códigos internos de 6 dígitos de Cencosud también lo tienen.

El Anexo II lo confirma: `productos_ean` vale 1 si `id_producto` es un EAN (GTIN-8 o GTIN-13) o un UPC-A, y 0 si es un código propio del comercio. Ese código propio debe tener 13 dígitos, ser estable en el tiempo y valer para todas las sucursales del comercio. DIA no cumple la norma cuando marca con 1 sus productos a granel.

Cuántos códigos se repiten entre comercios, sobre 70.357 códigos distintos:

Tipo de código (largo sin ceros a la izquierda)	Códigos	En 2 o más comercios
13 dígitos (EAN-13)	60.393	28,7 %
13 dígitos que empiezan con 2 (balanza o uso interno)	4.587	0,3 %
11 o 12 dígitos (UPC-A)	4.507	13,5 %
8 dígitos (EAN-8)	327	59,0 %
9 o 10 dígitos	10	2 códigos
7 dígitos o menos (internos)	533	0 %

Regla candidata (se decide en la etapa 2): un código es comparable si tiene 8 dígitos o más sin contar los ceros a la izquierda, no es de 13 dígitos que empiece con 2, y aparece en 2 o más comercios. Los demás productos se identifican por comercio × código.

- El 40,6 % de los precios (5,7 millones) es de códigos presentes en 5 o más comercios, y el 9,4 % (1,33 millones) de códigos que están en los 7. Esa es la base para elegir la canasta.
- Contar códigos da menos que contar precios: se repite el 25,8 % de los códigos, pero esos códigos cubren el 66,9 % de las filas.

Problemas de calidad encontrados

Los 7 comercios conservados también tienen problemas: días con productos o sucursales que faltan, precios de sucursales sin ubicar y provincias mal cargadas. Ninguno impide armar el pipeline, pero todos piden un control diario por comercio.

Problema	Dónde	Tratamiento propuesto
Productos que faltan un día y vuelven al siguiente	DIA, miércoles 13/10: 421.004 filas menos (−9,9 %) con las mismas 974 sucursales	Test de volumen por comercio. El historial de cambios tiene que tolerar ausencias cortas
Sucursales que no informan el domingo	Coop. Obrera, domingo 11/10: 96 de 156 sucursales (−239.715 filas)	Comparar siempre el mismo producto en la misma sucursal entre dos fechas

Problema	Dónde	Tratamiento propuesto
Precios de sucursales que no están en `sucursales.csv`	50.112 filas (0,36 %). El 99,9 % viene de las sucursales 1098 y 4001 de Dorinka	Se guardan en Drive, quedan fuera de los agregados por provincia y se cuentan cada día
Provincia mal cargada o vacía	DIA: 1 sucursal con "Buenos Aires". INC: 36 sucursales sin provincia	Normalizar con un diccionario, verificando la localidad. Sin provincia, quedan fuera de los agregados por provincia
Promociones no informadas	Cencosud y Dorinka (0 %), COTO (menos de 1 %)	La pregunta 4 se limita a las cadenas que informan
El conjunto de comercios cambia de un día a otro	Sábado 17/10: aparece el 8 y falta el 36	La lista explícita de 7 comercios lo evita. Se registra cuántas filas traen los demás
Línea de pie al final de cada CSV, con texto que varía	Todos los archivos	Descartar las filas con `id_comercio` no numérico y contarlas
Frutas y verduras a granel con `productos_ean = 1` y código inválido (empiezan con 249)	DIA, 33.033 filas	Quedan fuera de lo comparable por la regla de la sección anterior
Precio de promoción que no coincide con su leyenda (2245 sobre 2990 es 24,9 %, y la leyenda dice 25 %)	DIA, en un ejemplo	Usar el precio, no la leyenda
Fin de línea LF en lugar de CRLF	Varios comercios	Incumplen el Anexo II. La lectura ya lo tolera
Saltos de línea sin comillas dentro de latitud, longitud y horarios	`sucursales.csv` del comercio 6	Comercio descartado
Zip interno vacío (≈ 0 MB)	Comercio 36	Comercio descartado
Zips internos que no se pueden descomprimir	Comercios 6 y 36, lunes 12/10	Comercios descartados. No se sabe si el daño viene del portal o de la descarga

Problema	Dónde	Tratamiento propuesto
2 filas no numéricas de más en cada archivo	Comercio 47	Comercio descartado, sin inspeccionar
Viernes 16 sin publicar todavía el sábado	Portal	Verificar la fecha de la carpeta antes de cargar

Cambios a aplicar en el plan

Hay 26 cambios para el documento del plan, ordenados como sus secciones. El más importante sigue siendo que la descarga desde GitHub Actions no funciona, y eso obliga a rediseñar los pasos 3 y 4. Además, la etapa 1 quedó completa y tres decisiones pendientes quedaron resueltas.

Sección del plan	Qué dice hoy	Cambio
Encabezado y pie de cada página	"pipeline en la nube con MotherDuck"	Cambiar a BigQuery
Objetivo: volumen	"del orden de 12 millones de precios por día"	Más de 14,1 millones de filas por día en total, y unos 14 millones en los 7 comercios conservados
Objetivo: preguntas	"Preguntas candidatas (a confirmar después de explorar los datos)"	Confirmadas y ampliadas a 5 (ver Preguntas del proyecto)
Arquitectura	"La página nunca consulta BigQuery"	Pasa a ser una decisión pendiente de la etapa 5: JSON estáticos o una API sobre BigQuery
Componentes: GitHub Actions	"Ya hay un proyecto que baja SEPA desde ahí todos los días (changuito-sepa)"	Suavizarlo. No se pudo verificar, y desde GitHub Actions el portal responde 403
Proceso diario, paso 1	Cron "en un horario posterior a la publicación"	Los comercios envían hasta las 06:00 y rectifican hasta las 10:00. El portal publica cerca de las 13:19 de Argentina
Proceso diario, paso 2	Un archivo por día de la semana	Agregar que son 9 recursos: 7 zips, el Excel de provincias y el PDF de metadatos

Sección del plan	Qué dice hoy	Cambio
Proceso diario, pasos 3 y 4	La descarga la hace el runner	Pendiente de rediseño, porque el runner recibe 403
Proceso diario, paso 5	"Se descartan […] códigos de barras incorrectos"	Usar la regla de comparabilidad y normalizar las provincias
Proceso diario, paso 6	Un Parquet por fecha	Tres archivos por día: precios, productos y sucursales, unos 70 MB en total
Proceso diario, paso 11	Registro con filas leídas, descartadas y cargadas	Registrar filas y sucursales por comercio, no solo el total del día
Modelo de datos: `dim_productos`	Grano: producto (código de barras)	Grano: código comparable, o comercio × código para los no comparables
Modelo de datos: tablas de hechos	`fct_precios_agregados` y `fct_canasta`	Agregar `fct_precios_producto` para la pregunta 5, y evaluar un historial de cambios en lugar de una foto por día
Problemas: acceso al portal	"El portal a veces tarda en aceptar conexiones"	No es lentitud: es un bloqueo 403 por IP para conexiones desde la nube
Problemas: horario de publicación	Sin datos	Agregar los horarios observados y el límite de envío del Anexo II
Problemas: formato	"separador, codificación y columnas a confirmar"	Confirmados (ver Estructura y formato)
Problemas: licencia	"otro proyecto la indica como CC BY 4.0"	Confirmada en la página del dataset: CC BY 4.0
Problemas: disco y memoria	"Medir en la etapa 1"	Medido: 1,5 GB de CSV por día en los 7 comercios
Problemas: espacio en Drive	"Medir cuánto pesa un día en Parquet y proyectar"	Medido: 70 MB por día, unos 25 GB por año

Sección del plan	Qué dice hoy	Cambio
Problemas: identidad de los productos	"Usar solo productos con código de barras (EAN) válido: el archivo trae una marca para eso"	La marca no alcanza. Usar la regla candidata de comparabilidad
Problemas: qué precio usar	"Precio de lista para medir inflación"	Resuelto: precio de lista para las preguntas 1, 2, 3 y 5. Promociones solo para la 4
Problemas: fallas silenciosas	"Test de volumen: filas por día dentro de un rango esperado"	Hacerlo por comercio: el 13/10 el total bajó 3,1 % y escondió que DIA perdió el 9,9 %
Etapa 1	Notebook en Google Colab	Colab también recibe 403. Se hizo en la PC y está completa (ver Mediciones)
Decisiones pendientes	—	Resueltas: los comercios (7), el precio (de lista) y el archivo en Drive (7 cadenas, todo el país). Nuevas: desde dónde se descarga, foto o historial de cambios, tolerancia a ausencias, grano de los agregados, y el sitio y su API
Decisiones pendientes: canasta	"Por ejemplo, productos con código de barras que vendan todas las cadenas grandes"	Sigue abierta. Los códigos presentes en los 7 comercios suman 1,33 millones de filas por día, y el archivo no trae categoría
Fuentes	"Página oficial del dataset: no se pudo abrir"	Ya se abrió. Agregar el Anexo II como fuente de la especificación

Preguntas abiertas y próximos pasos

Lo único que impide pasar a la etapa 3 es el bloqueo de acceso. Todo lo demás se puede seguir midiendo en la PC.

- [ ] Escribir a soportesepa@comercio.gob.ar para preguntar si el bloqueo es por país o por tipo de conexión, y si hay una vía autorizada para descargas automáticas.
- [ ] Repetir la prueba desde GitHub Actions otro día y en otro horario.

- [ ] Evaluar alternativas: otra fuente (por ejemplo, gondolar) o descargar desde la PC aprovechando el margen de 7 días.
- [x] ~~Verificar la fecha de todas las carpetas del sábado: las 16 tienen 2026-10-17.~~
- [x] ~~Medir el peso de un día en Parquet y las filas después de agregar.~~
- [x] ~~Confirmar en el Anexo II la definición de `productos_ean`.~~
- [x] ~~Medir el ritmo de cambios en días consecutivos.~~
- [x] ~~Comparar precios de Cencosud entre fechas: sí cambian, el 15,2 % de sus claves en la semana.~~
- [ ] Averiguar por qué DIA perdió 421.004 filas el 13/10, y si se repite.
- [ ] Confirmar si Coop. Obrera informa menos sucursales todos los domingos.
- [ ] Revisar las sucursales 1098 y 4001 de Dorinka, que no están en `sucursales.csv`. ¿Son tiendas online?
- [ ] Verificar la localidad de la sucursal de DIA con provincia "Buenos Aires" antes de pasarla a `AR-B`.
- [ ] Revisar si DIA y Dorinka, que nunca usan `productos_ean = 0`, tienen otros códigos de balanza marcados como 1.
- [ ] Comparar `comercio_version_sepa` con el prefijo `sepa_1` / `sepa_2`.
- [ ] Aplicar al plan los cambios de la sección anterior.